Estructuras de datos en R

Vectores atómicos, listas, matrices, factores, data frames y tibbles

Dr. Samuel D. Gamboa Tuz

Ι

Vectores

- Conjuntos de uno (scalar) o varios valores, o elementos.
- Propiedades:
 - Tipo. Se checa con la función typeof().
 - Longitud. Se checa con la función length().
 - Atributos. Se checa con la función attributes().
- Se dividen en **vectores atómicos** y **listas**.
- Vectores atómicos:
 - Contiene valores homogéneos (un solo tipo).
 - Se construyen con la funcion c() (combine).
 - Cuatro tipos: integer, double, character, logical.
- Listas:
 - Pueden contener valores heterogéneos (varios tipos).
 - Se construyen con la función list().
 - Único tipo: list.

Tipos de vectores atómicos y listas

integer, double, character, logical, list

integer (int)

• Valores numéricos enteros seguidos por la letra L.

```
int_vector <- c(1L, 4e3L, NA, 0L, -5L, 600L)
 int_vector
## [1]
          1 4000
                   NA
                                600
 typeof(int_vector)
## [1] "integer"
 is.integer(int_vector)
## [1] TRUE
 length(int_vector)
## [1] 6
```

• También se pueden crear con la función seq() o el operador : usando números enteros. ¿Habrá más formas?

double (dbl)

- Double-precision floating-point.
- Valores numéricos con punto decimal. Ej. 0.1, 10.0, -5.5, 6.6e-3.
- En la práctica, R convierte todos los números que ingresamos a tipo double.

```
dbl_vector <- c(NaN, 4e-05, -3, Inf, 5.0, NA)
 dbl_vector
## [1] NaN 4e-05 -3e+00 Inf 5e+00
                                             NA
 typeof(dbl_vector)
## [1] "double"
 is.double(dbl_vector)
## [1] TRUE
 length(dbl_vector)
## [1] 6
```

character (chr)

• Valores (strings) encerrados en comillas simples (') o dobles (").

```
chr_vector <- c("1", "", "frase o palabra", NA, "NA", 200)</pre>
 chr_vector
                           11 11
                                              "frase o palabra"
## [1] "1"
                                              "200"
## [4] NA
                           "NA"
 typeof(chr_vector)
## [1] "character"
 is.character(chr_vector)
## [1] TRUE
 length(chr_vector)
## [1] 6
```

logical (lgl)

• Valores de verdadero o falso.

```
lgl_vector <- c(TRUE, FALSE, NA, F, T, TRUE)</pre>
 lgl_vector
## [1] TRUE FALSE NA FALSE TRUE TRUE
 typeof(lgl_vector)
## [1] "logical"
 is.logical(lgl_vector)
## [1] TRUE
 length(lgl_vector)
## [1] 6
```

Coerción de vectores atómicos

- character > double > integer > logical.
- ¿Cuál será el tipo de estos vectores atómicos?

```
a <- c("a", 2.0, 1L, TRUE, NA)

## [1] "a" "2" "1" "TRUE" NA

b <- c(5.5, 1L, FALSE, NA)

b

## [1] 5.5 1.0 0.0 NA

c <- c(1L, TRUE, FALSE, NA)

c ## [1] 1 1 0 NA
```

Coerción explícita

- Se puede convertir de un tipo de vector a otro con funciones as.*().
- Cuando no sea posible, se asignan NAs.

```
x <- c("1", "2", "3", "cuatro", "T", "FALSE")
is.character(x)
## [1] TRUE
as.double(x)
## Warning: NAs introduced by coercion
## [1] 1 2 3 NA NA NA
as.integer(x)
## Warning: NAs introduced by coercion
## [1] 1 2 3 NA NA NA
as.logical(x)
                           NA TRUE FALSE
## [1]
         NA
               NA
                     NA
```

```
y \leftarrow c(1, 2, -3, 4.3, 5.5, 0)
 is.double(y)
## [1] TRUE
 as.logical(y)
## [1] TRUE TRUE TRUE TRUE TRUE FALSE
 as.character(y)
## [1] "1" "2" "-3" "4.3" "5.5" "0"
 as.integer(y)
## [1] 1 2 -3 4 5 0
```

- En la coerción de *double* o *integer* a *logical*, los ceros se convierten en FALSE y cualquier otro número se convierte en TRUE.
- En la coerción de *double* a *integer*, los decimales se pierden.

```
z <- c(TRUE, FALSE, TRUE, FALSE, NA)
 is.logical(z)
## [1] TRUE
 as.character(z)
## [1] "TRUE" "FALSE" "TRUE" "FALSE" NA
 as.double(z) # o as.integer(z)
## [1] 1 0 1 0 NA

    Puedes sumar el número o proporción de valores TRUE en un vector con sum() o

    mean(), pero hay que elimnar los NAs antes con na.omit().
 sum(na.omit(z))
## [1] 2
 mean(na.omit(z))
## [1] 0.5
```

list

- Una lista es una colección de objetos, los cuales pueden ser vectores atómicos (de diferentes tipos), otras listas, matrices, data frames, etc.
- Se crean con la función list().

[1] TRUE FALSE

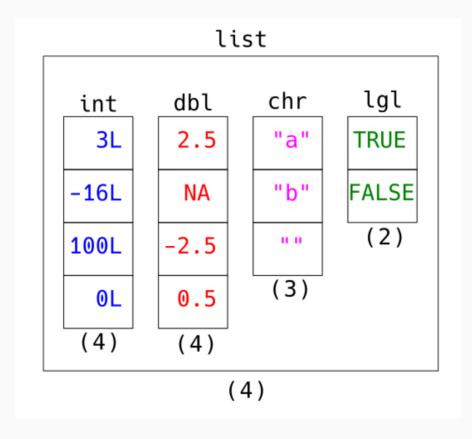
NA FALSE TRUE TRUE

```
str(list_vector)
## List of 4
## $ : int [1:6] 1 4000 NA 0 -5 600
## $ : num [1:6] NaN 4e-05 -3e+00 Inf 5e+00 ...
## $ : chr [1:6] "1" "" "frase o palabra" NA ...
## $ : logi [1:6] TRUE FALSE NA FALSE TRUE TRUE
 typeof(list_vector)
## [1] "list"
 is.list(list_vector)
## [1] TRUE
 length(list_vector)
## [1] 4
```

• En este ejemplo, no importaría si un elemento de la lista tuviera una longitud de 1000, la longitud de la lista seguiría siendo cuatro.

En resumen...

- Hay cuatro tipos principales de vectores atómicos: *integer*, *double*, *character*, *logical*.
- Una lista (tipo *list*) es una colección de otros elementos; por ejemplo, vectores atómicos de diferentes tipos y longitudes, u otras listas.



Vectores con nombres

Atributo names

attributes

- Metadatos asociados a un vector o a sus elementos.
- Se pueden checar con la función attributes().

```
attributes(dbl_vector)

## NULL

attributes(list_vector)

## NULL
```

names

NULL

- El atributo *names* es un vector tipo *character* de la misma longitud que el vector nombrado.
- Se utiliza la función names() para checar, asignar y borrar nombres.

```
names(dbl_vector)
## NULL
names(dbl_vector) <- c("A", "B", "C", "D", "E", "F")</pre>
 dbl_vector
## NaN 4e-05 -3e+00 Inf 5e+00
                                          NA
names(dbl_vector)
## [1] "A" "B" "C" "D" "F" "F"
 names(dbl_vector) <- NULL # Quitar nombres</pre>
names(dbl_vector)
```

17

 También se puede asignar los nombres directamente al momento de crear un vector.

```
named\_vector1 <- c("a" = 1, "b" = 2, "c" = 3)
 named_vector2 <- c("1" = "a", "2" = "b", "3" = "d")
 named_vector1
## a b c
## 1 2 3
named_vector2
## 1 2 3
## "a" "b" "d"
 attributes(named_vector1)
## $names
## Г1] "a" "b" "c"
names(named_vector2)
## [1] "1" "2" "3"
```

• En una lista, se puede nombrar sus elementos y los elementos de los vectores que contiene; se decir, puede contener dos o más juegos de nombres (depediendo de la estructura de la lista).

```
named_list <- list(named_vector1, named_vector2)</pre>
 names(named_list) <- c("vector1", "vector2")</pre>
 named_list
## $vector1
## a b c
## 1 2 3
##
## $vector2
## 1 2 3
## "a" "b" "d"
 attributes(named_list)
## $names
## [1] "vector1" "vector2"
 names(named_list)
## [1] "vector1" "vector2"
```

str(named_list)

```
## List of 2
## $ vector1: Named num [1:3] 1 2 3
## ..- attr(*, "names")= chr [1:3] "a" "b" "c"
## $ vector2: Named chr [1:3] "a" "b" "d"
## ..- attr(*, "names")= chr [1:3] "1" "2" "3"
```

• Nos podemos referir a los elementos de una lista por su nombre haciendo uso del operador \$ (adelanto de *subsetting*).

```
named_list$vector1

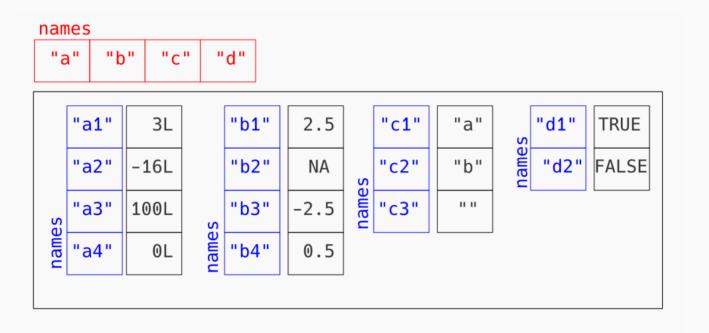
## a b c
## 1 2 3

named_list$vector2
```

```
## 1 2 3
## "a" "b" "d"
```

En resumen...

- El atributo names son metadatos en la forma de vectores tipo *character* de la misma longitud que los vectores que nombran.
- Sirve para identificar y referirse a los elementos de un vector.



Matrices

Atributos dim y dimnames

Matrices

- Una matriz es un vector atómico con dos dimensiones: número de filas y número de columnas.
- Se utiliza la función dim() para checar, agregar, y quitar dimensiones (similar a names()).

```
m1 < -c(1, 2, 3, 4, 5, 6)
 dim(m1)
## NULL
 dim(m1) <- c(2, 3)
 m1
## [,1] [,2] [,3]
## [1,] 1 3 5
## [2,] 2 4 6
 attributes(m1)
## $dim
## [1] 2 3
```

```
is.matrix(m1)

## [1] TRUE

typeof(m1)

## [1] "double"

dim(m1) <- NULL
is.matrix(m1)

## [1] FALSE</pre>
```

• Por lo general, las matrices se crean con la función matrix().

```
dimnames(mat) <- NULL</pre>
 mat
## [,1][,2][,3]
## [1,] 1 2 3
## [2,] 4 5 6
 rownames(mat) <- c("ROW1", "ROW2")</pre>
 colnames(mat) <- c("COL1", "COL2", "COL3")</pre>
 mat
## COL1 COL2 COL3
## ROW1 1 2 3
## ROW2 4 5 6
 attributes(mat)
## $dim
## [1] 2 3
##
## $dimnames
## $dimnames[[1]]
## [1] "ROW1" "ROW2"
##
## $dimnames[[2]]
## [1] "COL1" "COL2" "COL3"
```

Puedes preguntarle a R el número de filas o columnas de una matriz con nrow() y ncol(), o dim.

```
nrow(mat)
## [1] 2

ncol(mat)
## [1] 3

dim(mat)
## [1] 2 3
```

 La longitud de una matriz corresponde al número de elementos en ella, como un vector atómico.

```
length(mat)
## [1] 6
```

• Si dos matrices tienen el mismo número de filas, se pueden unir con cbind().

```
mat1 <- matrix(1:10, 5); mat2 <- matrix(1:15, 5)
  cbind(mat1, mat2)

## [,1] [,2] [,3] [,4] [,5]
## [1,] 1 6 1 6 11</pre>
```

```
## [1,] 1 6 1 6 11
## [2,] 2 7 2 7 12
## [3,] 3 8 3 8 13
## [4,] 4 9 4 9 14
## [5,] 5 10 5 10 15
```

 Si dos matrices tienen el mismo número de columnas, se pueden unir con rbind().

```
mat3 <- matrix(letters[1:10], 2, 5); mat4 <- matrix(1:15, 3, 5)
rbind(mat3, mat4)</pre>
```

```
## [,1] [,2] [,3] [,4] [,5]

## [1,] "a" "c" "e" "g" "i"

## [2,] "b" "d" "f" "h" "j"

## [3,] "1" "4" "7" "10" "13"

## [4,] "2" "5" "8" "11" "14"

## [5,] "3" "6" "9" "12" "15"
```

Se aplican las mismas reglas de coerción que con los vectores atómicos.

• Las matrices pueden tranponerse con la función t().


```
mat <- matrix(rep(c(T,F), 10), 2)
mat
##
        [,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8] [,9] [,10]
## [1,] TRUE TRUE TRUE TRUE TRUE
                                   TRUE TRUE TRUE TRUE TRUE
## [2,] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
t(mat)
##
        [,1] [,2]
##
   [1,] TRUE FALSE
   [2,] TRUE FALSE
##
   [3,] TRUE FALSE
##
   [4,] TRUE FALSE
   [5,] TRUE FALSE
##
   [6,] TRUE FALSE
##
   [7,] TRUE FALSE
##
   [8,] TRUE FALSE
##
##
  [9,] TRUE FALSE
## [10,] TRUE FALSE
```

 Cuando la matriz es numérica (integer o double) or logical se pueden sumar los elementos u obtener su promedio por columna o fila con colSums(), colMeans(), rowSums() y rowMeans().

```
colSums(mat)
## [1] 1 1 1 1 1 1 1 1 1 1
colMeans(mat)
  rowSums(mat)
## [1] 10 0
rowMeans(mat)
## [1] 1 0
```

En resumen...

- Una matriz es un vector atómico de dos dimensiones indicadas por el atributo dim (número de filas y columnas); dim es un vector de tipo integer y longitud 2.
- Las columnas y filas pueden estar nombradas con el atributo *dimnames* (nombre de las dimensiones); *dimnames* es una lista con dos vectores de tipo *character*.



Factores, data frames y tibbles

Atributo class

factor (fct)

- Vectores que se utilizan para almacenar datos categóricos.
- Se crean con la función factor() a partir de un vector atómico.

```
x <- as.integer(c(1, 2, 3, 1, 2, 3))
fct_vector <- factor(x)
fct_vector

## [1] 1 2 3 1 2 3
## Levels: 1 2 3</pre>
```

• El tipo de un factor es *integer*, pero **no** se comporta como numérico.

```
typeof(fct_vector)

## [1] "integer"

fct_vector * 10

## Warning in Ops.factor(fct_vector, 10): '*' not meaningful for
## factors

## [1] NA NA NA NA NA NA
```

• Tiene dos atributos: levels y class factor.

```
attributes(fct_vector)
## $levels
## [1] "1" "2" "3"
##
## $class
## [1] "factor"
  • Se pueden checar el número de levels con nlevels() y sus valores con
    levels()
 nlevels(fct_vector)
## [1] 3
 levels(fct_vector)
## [1] "1" "2" "3"
```

- El atributo *levels* es un vector de tipo *character* que contiene los valores (categorías) posibles, por *default* en orden alabético.
- Se puede especificar o cambiar el orden de los levels, y las etiquetas, con factor().

• El orden y las etiquetas de los <u>levels()</u> es relevante al momento de crear gráficas.

data.frame

• Los data frames se crean con la función data. frame() a partir de vectores atómicos (de "una dimensión") de una misma longitud; estos vectores pueden ser de diferentes tipos.

```
## 3
             NA
                    -3e+00 frase o palabra
                                                   NA
                                                           three
## 4
             0
                       Inf
                                      <NA>
                                                FALSE
                                                             one
## 5
            -5
                     5e+00
                                                TRUE
                                        NA
                                                             two
## 6
            600
                        NA
                                       200
                                                 TRUE
                                                           three
```

str(df)

```
## 'data.frame': 6 obs. of 5 variables:
## $ int_vector: int 1 4000 NA 0 -5 600
## $ dbl_vector: num NaN 4e-05 -3e+00 Inf 5e+00 ...
## $ chr_vector: chr "1" "" "frase o palabra" NA ...
## $ lgl_vector: logi TRUE FALSE NA FALSE TRUE TRUE
## $ fct_vector: Factor w/ 3 levels "three", "two", ..: 3 2 1 3 2 1
```

- Un data frame tiene tres atributos:
 - 1. **names.** Nombres de las columnas.
 - 2. class. Tiene la clase data.frame.
 - 3. row.names. Nombres de las filas.

attributes(df)

```
## $names
## [1] "int_vector" "dbl_vector" "chr_vector" "lgl_vector"
## [5] "fct_vector"
##
## $class
## [1] "data.frame"
##
## $row.names
## [1] 1 2 3 4 5 6
```

• La longitud del *data frame* es igual a su número de columnas y su tipo es *list*.

```
length(df)

## [1] 5

typeof(df)

## [1] "list"
```

 Al igual que una matriz, un data.frame tiene dos dimensiones: número de filas y número de columnas.

```
dim(df); nrow(df); ncol(df)

## [1] 6 5

## [1] 6

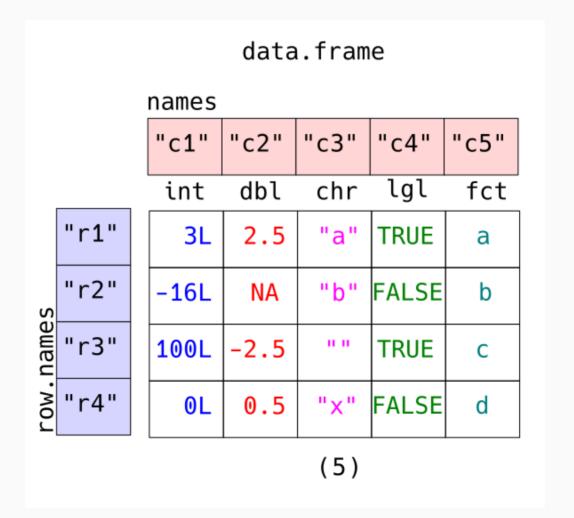
## [1] 5
```

• Los nombres de las filas pueden modificarse con row.names() y los nombres de las columnas con names(). También con dimnames().

```
row.names(df) <- letters[1:6] # o rownames()</pre>
 names(df) <- LETTERS[1:5] # o colnames()</pre>
 df
                                           Ε
##
              В
                               1 TRUE
## a
             NaN
                                         one
                                 FALSE
## b 4000 4e-05
                                         two
## c
      NA -3e+00 frase o palabra
                                    NA three
## d
             Inf
                            <NA> FALSE
     0
                                         one
                              NA TRUE
## e -5 5e+00
                                         two
                             200 TRUE three
## f 600
              NA
```

En resumen...

- En la práctica, un data frame funciona como una tabla.
- Un data frame tiene características de matriz y de lista.



tibble

- Un tibble es muy similar a un data frame.
- Se crea con la función tibble() del paquete tibble (si instalaste el Tydiverse, ya tienes instalado Tibble):

```
tbl <- tibble::tibble(int_vector, dbl_vector,
                         chr_vector, lgl_vector,
                         fct vector)
## # A tibble: 6 x 5
     int_vector dbl_vector chr_vector
                                             lgl_vector fct_vector
                     <dbl> <chr>
                                             < lgl >
                                                        <fct>
##
          <int>
                           "1"
                                             TRUE
## 1
                 NaN
                                                        one
## 2
          4000 0.00004
                                             FALSE
                                                        two
                      "frase o palabra" NA
## 3
             NA -3
                                                        three
## 4
              0
                 Inf
                          <NA>
                                             FALSE
                                                        one
                           "NA"
## 5
             -5
                                             TRUE
                                                        two
                           "200"
## 6
            600
                  NA
                                             TRUE
                                                        three
 class(tbl)
                                 "data.frame"
## [1] "tbl df"
                    "tbl"
```

str(tbl)

```
## tibble [6 × 5] (S3: tbl_df/tbl/data.frame)
## $ int_vector: int [1:6] 1 4000 NA 0 -5 600
## $ dbl_vector: num [1:6] NaN 4e-05 -3e+00 Inf 5e+00 ...
## $ chr_vector: chr [1:6] "1" "" "frase o palabra" NA ...
## $ lgl_vector: logi [1:6] TRUE FALSE NA FALSE TRUE TRUE
## $ fct_vector: Factor w/ 3 levels "three", "two", ...: 3 2 1 3 2 1
```

- Por default, un *tibble* solo imprime las primeras 10 filas y te indica cuantas más contiene el data set.
- Cuando no todas las columnas alcanzan a mostrarse en pantalla, solo imprime los nombres de las faltantes en la parte de abajo (puedes ver el objeto completo con View()).
- Debajo del nombre de cada columna se indica el tipo de vector de la columna.
- Los tibbles no usan row.names.
- El resultado applicar un subset con [] a un *tibble* siempre es un *tibble*.

Veamos un ejemplo con dataset más grande...

• Puedes transformar un data frame en un tibble con as_tibble()

```
tbl_mtcars <- tibble::as_tibble(mtcars) # Datos precargados en R
tbl_mtcars</pre>
```

```
## # A tibble: 32 x 11
##
                                                               cvl disp
                                                                                                                          hp drat
                                    mpg
                                                                                                                                                                                 wt qsec
                                                                                                                                                                                                                                         ٧S
                                                                                                                                                                                                                                                                                      gear
                           <dbl> 
##
                           21
                                                                                   160
                                                                                                                      110
                                                                                                                                             3.9
                                                                                                                                                                         2.62
                                                                                                                                                                                                16.5
##
                1
                                                                                                                                                                                                                                               0
                                                                                                                                                                                                                                                                                                      4
##
                 2
                              21
                                                                                   160
                                                                                                                      110
                                                                                                                                             3.9
                                                                                                                                                                         2.88
                                                                                                                                                                                                 17.0
                                                                                                                                                                                                                                               0
                                                                                                                                                                                                                                                                                                      4
##
                 3 22.8
                                                                                   108
                                                                                                                   93
                                                                                                                                             3.85
                                                                                                                                                                         2.32
                                                                                                                                                                                                  18.6
                                                                                                                                                                                                                                                                                                      4
##
                4 21.4
                                                                        6 258
                                                                                                                      110
                                                                                                                                           3.08
                                                                                                                                                                      3.22
                                                                                                                                                                                                 19.4
                                                                                                                                                                                                                                                                                                      3
##
                 5 18.7
                                                                        8 360
                                                                                                                      175
                                                                                                                                           3.15
                                                                                                                                                                      3.44
                                                                                                                                                                                                 17.0
##
                6 18.1
                                                                        6 225
                                                                                                                      105
                                                                                                                                             2.76
                                                                                                                                                                     3.46 20.2
               7 14.3
                                                                                   360
                                                                                                                                                                   3.57 15.8
##
                                                                                                                      245
                                                                                                                                           3.21
##
                8 24.4
                                                                                   147.
                                                                                                                          62
                                                                                                                                           3.69 3.19 20
                                                                                                                                                                                                                                                                          0
                                                                                                                                                                                                                                                                                                      4
##
                9 22.8
                                                                                   141.
                                                                                                                          95
                                                                                                                                           3.92
                                                                                                                                                                         3.15 22.9
                                                                                                                      123
                                                                                                                                             3.92
## 10
                            19.2
                                                                                   168.
                                                                                                                                                                         3.44 18.3
                                                                                                                                                                                                                                                                          0
                                                                                                                                                                                                                                                                                                      4
## # ... with 22 more rows, and 1 more variable: carb <dbl>
```

• También puedes construir un *tibble* con **tribble()**, pero a veces no es muy práctico:

```
tbl_tr <- tibble::tribble(
    ~x, ~y, ~z,
    1, 2, "a",
    3, 4, "b",
    5, 6, "c",
    7, 8, "d",
    9, 10, "e`"
)
tbl_tr</pre>
```

Importar y exportar data frames y tibbles

read.table()

- Para importar debes pasar el path y nombre del archivo a la función read.table(). Puede ser una liga de internet.
- Importemos el dataset de palmer penguins.

```
species island bill_length_mm bill_depth_mm flipper_length_mm
##
## 1 Adelie Torgersen
                              39.1
                                           18.7
                                                            181
## 2 Adelie Torgersen
                              39.5
                                           17.4
                                                            186
    body_mass_g sex year
##
          3750 male 2007
## 1
## 2
          3800 female 2007
```

- Hay varias variantes de read.table(), como read.csv(), etc.
- Una vez importado el dataset se puede convertir en una matriz con as.matrix()
 o en un tibble con as_tibble().

readr::read_csv()

 Se puede importar directamente una tabla de datos como tibble con las funciones read_csv() o read_tsv(), etc. del paquete readr (viene con el tidyverse).

```
tbl_penguins <- readr::read_csv(penguin_filename)
tbl_penguins</pre>
```

```
## # A tibble: 344 x 8
      species island bill_length_mm bill_depth_mm flipper_length_...
##
     <chr>
              <chr>
                              <dbl>
                                            <dbl>
                                                              <dbl>
##
   1 Adelie Torge...
                               39.1
                                             18.7
                                                                181
   2 Adelie Torge...
                               39.5
                                             17.4
##
                                                                186
   3 Adelie Torge...
##
                               40.3
                                             18
                                                                195
##
   4 Adelie Torge...
                               NA
                                             NA
                                                                NA
   5 Adelie Torge...
##
                               36.7
                                             19.3
                                                                193
   6 Adelie Torge...
##
                               39.3
                                             20.6
                                                                190
   7 Adelie Torge...
##
                               38.9
                                             17.8
                                                                181
   8 Adelie Torge...
##
                               39.2
                                             19.6
                                                                195
   9 Adelie Torge...
                                             18.1
##
                               34.1
                                                                193
                                              20.2
## 10 Adelie Torge...
                               42
                                                                190
## # ... with 334 more rows, and 3 more variables: body_mass_g <dbl>,
## # sex <chr>, year <dbl>
```

write.table() y readr::write_csv()

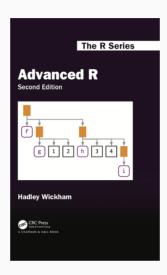
 Los datos se pueden exportar como tablas con cuaquiera de las funciones write*():

Actividades recomendadas

- ¿Qué información nos dan las funciones mode(), typeof() y class()?
- Aplica esas funciones a las diferentes estructuras de datos que vimos en esta presentación y compara.
- ¿Para qué sirven y cómo se utilizan las funciones setNames() y unname()?
- ¿Que otros tipos de vectores atómicos existen?
- ¿Qué vectores almacenan fechas y horas en R?
- ¿Cómo se importan datos desde una hoja de cálculo de Excel?

Bibliografía recomendada

Advanced R - Hadley Wickham



Capítulo 3 - Vectores

https://adv-r.hadley.nz/vectors-chap.html